

데이터 마이닝 특론


Week 1

Topics

- 과목 소개
- 데이터 마이닝 개요

데이터 마이닝 (Data Mining)

- 대규모 데이터에서 숨겨진 패턴, 규칙, 관계 등을 탐색하고 의미 있는 정보를 추출하는 기술 및 프로세스
- 기계 학습, 통계, 데이터베이스 기술을 융합하여 방대한 데이터 집합에서 가치 있는 지식과 인사이트를 찾아내는 일련의 과정
- 단순히 데이터를 채굴하는 것이 아니라, 데이터 내에 숨어 있는 유의미한 패턴과 관계를 분석하여 의사결정 및 문제 해결에 활용



데이터 마이닝의 주요 단계




데이터 마이닝 기법

- 예측 모델링
- 군집화(Clustering)
- 분류(Classification)
- 연관 규칙 학습(Association Rule Learning) 등


회귀분석 (Regression)

- In statistical modeling, regression analysis is a set of statistical processes for estimating the relationships among variables. 변수들 사이의 관계를 추정하는 통계기법




분류 (Classification)

- A machine learning technique that uses known data to determine how the new data should be classified into a set of existing categories.
- 기본의 데이터를 이용하여
어떻게 새로운 데이터를 기존의
범주로 분류할지 결정하는
머신러닝 기술




로지스틱 회귀분석 (Logistic Regression)

- A supervised learning classification algorithm used to predict the probability of a target variable. 종속변수의 확률을 예측하는 데 사용되는 분류 알고리즘
- The nature of target or dependent variable is dichotomous, which means there would be only two possible classes. 2개의 클래스를 가진 문제에 적합



$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p$$



$$p(X) = e^{\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p} / (1 + e^{\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_p X_p})$$

- Used to predict the probability that an individual observation falls into a certain category. 어떤 카테고리에 속하는 지 확률을 예측하는 데 사용됨

분류 알고리즘 (Classification Algorithms)

Decision Tree
의사결정트리

Random Forest
랜덤포레스트

Linear Discriminant
Analysis
선형판별분석

K-Nearest Neighbor
K-최근접이웃


Support Vector
Machine
지원벡트머신

Neural Network
신경망

군집분석 (Clustering)


유사한 데이터
그룹화

- The process of grouping similar entities together.
비슷한 것끼리 묶는 기술
- 예) 고객 세분화, 상품 카테고리 분류



연관성 분석 (Association Rules)

- A technique to uncover how items are associated to each other 어떤 아이템끼리 관련이 있는지 발견하는 기술
- Cross-selling opportunities, recommendation engine effectiveness 추천시스템이나 같이 파는 물건을 찾아내는 기회



딥러닝 기반 데이터 분석 기법



- CNN (Convolutional Neural Network)
- RNN (Recurrent Neural Network), LSTM (Long Short-Term Memory)
- GAN (Generative Adversarial Network)

이미지 분류 모델 및 언어 모델


- 합성곱 신경망 (CNN)

- 이미지 처리를 위해
컨볼루션 신경망을 사용

- 순환신경망 (RNN)과 LSTM:
자연어 처리를 위해 순환
신경망을 사용



신경망 아키텍처의 발전



생성적 적대적 신경망 (Generative Adversarial Network, GAN)

- 두 개의 신경망(Generator, Discriminator)이 경쟁하며 학습하는 방식
- 이미지 생성 (딥페이크, 화풍 전환 등), 비디오 생성, 데이터 증강 등에 사용
- 원리 및 구조
 - Generator: 가짜 데이터를 생성
 - Discriminator: 진짜 데이터와 가짜 데이터를 구분
 - 경쟁적 학습: Generator가 점점 더 진짜 같은 데이터를 생성하게 됨

빅데이터 분석 기법

- 텍스트 마이닝
- 자연어처리
- 클러스터링
- 토픽모델링 등

텍스트 마이닝 (Text Mining)



- 뉴스, 리뷰, SNS, 고객 의견, 설문조사 같은 비정형 텍스트 데이터에서 의미 있는 정보와 패턴을 추출하는 분석 방법

규칙/어휘 기반
감성분석


M/L 기반
감성분석

딥러닝 기반
감성분석

대규모 텍스트
에서 의미 추출




$$y = f(x)$$



자연어 처리 (Natural Language Processing, NLP)

언어 이해 및
처리

- 컴퓨터가 사람이 사용하는 언어(텍스트, 음성)를 이해하고 분석하거나 생성하도록 하는 기술



- nlTK 라이브러리 사용하여 분류, 토큰화, 스템밍, 테깅, 파싱, 의미추론, 래퍼 등과 같은 문자처리

토픽 모델링 (Topic Modeling)

텍스트 내 잠재 주제 파악

- 문서에서 숨겨진 주제(Topic)를 찾아내는 방법
- 예) 텍스트 마이닝 기법을 활용한 COVID-19 발생 이전, 이후의 배달주문플랫폼 서비스에 대한 주요 토픽 분석

순위	2019			2020		
	토픽 1 (36.6%)	토픽 2 (35.1%)	토픽 3 (28.3%)	토픽 1 (38.8%)	토픽 2 (32.0%)	토픽 3 (29.2%)
1	이벤트	배달	좋아요	주문	기업	민족
2	요기요	최고	편리	쿠폰	소상공인	좋아요
3	쿠폰	음식	좋음	시간	탈퇴	배신
4	배민	민족	편해요	가게	삭제	감사
5	리뷰	감사	좋네요	결제	수수료	배달
6	어플	배민	사용	음식	시국	사용
7	이용	어플	만족	메뉴	요기요	코로나
8	결제	좋은	감사	리뷰	배신의민족	삭제
9	주문	결제	이용	전화	코로나	수수료
10	배달민족	리뷰	좋습니다	배달	어플	이용

배달플랫폼
프로모션 관련

음식배달
만족도 관련

사용편의성
관련

배달 플랫폼
이용

‘COVID-19 상
황에서 배달주문
플랫폼에 대한 불만

배달주문플랫폼
독과점에 대한
배신감 관련 토픽

인공지능, 머신러닝, 딥러닝의 관계

Artificial Intelligence

Any technique which enables computers to mimic human behavior.

컴퓨터가 사람의 행동을 흉내내는 모든 기술들

Fuzzy logic
Genetic algorithm
Expert system

Machine Learning

Subset of AI techniques which use statistical methods to enable machines to improve with experiences.

통계적 방법을 이용하여 기계가 학습하게 하는 인공지능 기술


Neural network

Deep Learning

Subset of ML which make the computation of multi-layer neural networks feasible.


다중층 신경망을 이용하는 머신러닝 기술

인공지능(AI) ⊃ 머신러닝(ML) ⊃ 딥러닝(DL)





인공지능 (Artificial Intelligence)

- The science of making machines imitate human thinking and behavior, can replace human decision making in some instances. 기계가 인간의 생각, 행동을 모방하여 어느 정도 인간의 의사결정을 대체할 수 있게 하는 과학



신경망 아키텍처

- Structures algorithms in layers to create an “artificial neural network” that can learn and make intelligent decisions on its own. 스스로 학습하고 지능적인 결정을 내릴 수 있는 "인공 신경망"을 만들기 위해 알고리즘을 레이어로 구조화



AI와 딥러닝을 활용한 예측 분석

- 매출 예측: 과거 데이터와 트렌드를 분석하여 미래 매출 예측
- 재고/수요 예측: 소비자 행동을 예측하여 제품 생산량과 재고 관리 최적화
- 시장 변화 예측: 경쟁사의 활동, 시장 동향 및 외부 경제 요인을 분석하여 향후 시장 변화를 예측
- 부정거래 예측: 거래 패턴과 고객 행동 데이터를 분석하여 이상 거래 및 부정거래 가능성을 사전에 탐지

AI와 딥러닝을 활용한 고객 분석

- 고객 세분화: AI를 이용해 고객을 유사한 특성 별로 자동 분류
- 고객 행동 분석: 딥러닝을 활용하여 고객의 행동 패턴을 분석하고 향후 행동을 예측
- 맞춤형 마케팅: 고객 세그먼트에 맞춘 개인화된 마케팅 전략 수립
- 추천 시스템: AI 기반 추천 알고리즘을 통해 제품 또는 서비스를 추천

Lab #0

- Post your introduction on the discussion board.
자기소개를 이클래스 토론방에 올려주세요.