

데이터 마이닝 특론

Week 4

서울과학기술대학교
SEOULTECH Seoul National University of Science & Technology

Topics

- 탐색적 데이터 분석 (EDA)
- 붓꽃 데이터 EDA 실습

EDA (Exploratory Data Analysis)
탐색적 데이터분석

- 본격적인 모델링이나 통계적 가설 검정에 들어가기 전, 다양한 각도에서 데이터를 관찰하고 주요 특성을 파악하는 초기 분석 과정. Before starting full-scale modeling or statistical hypothesis testing, the initial analysis process involves observing data from various angles and identifying key characteristics.
- 모델링 전에 데이터를 탐색하고 요약. Explore and summarize data before modeling.

데이터 이해

- 데이터의 구조, 형태, 변수별 분포를 직관적으로 확인

기본 통계 분석

- 데이터 크기, 타입, 평균, 표준편차, 요약 통계량을 확인

데이터 시각화

- 히스토그램, 박스 플롯, 산점도 등을 활용해 자료를 시각적으로 표현

수질검사 현황 데이터 EDA

- 각 컬럼이 계량형으로 각각의 지역에서 측정한 값으로 구성되어 있고, 검사항목이 범주형으로 측정에 사용한 검사항목으로 구성

  - 유입하천의 수질조사 결과

	A	B	C	D	E	F	G	H
1		통학교	동정교	천천1교	오봉교	섬티교	구암교	금성교
2	채수일	8/18/2015	8/18/2015	8/18/2015	8/18/2015	8/18/2015	8/18/2015	8/18/2015
3	검사완료일	8/31/2015	8/31/2015	8/31/2015	8/31/2015	8/31/2015	8/31/2015	8/31/2015
4	수온	23.1	22.5	23	23	23.9	25.6	25.8
5	수소이온농도	7.3	7.9	7.9	8	8.1	8	8
6	용존산소	9.9	10.3	9.5	9.6	9.4	9.5	8.5
7	전기전도도	165	192	181	350	158	109	106
8	생화학적 산소요구량	0.5	0.7	0.6	0.6	0.9	0.6	0.6
9	화학적 산소요구량	2.3	3.4	3.1	2.9	2.8	2.1	1.8
10	암모니아성 질소량	0.055	0.066	0.078	0.098	0.062	0.098	0.09
11	이산화질소성 질소량	0.012	0.013	0.012	0.006	0.007	0.004	0.007
12	질산염성 질소량	2.015	1.584	1.712	2.63	0.853	0.69	0.993
13	총질소	2.159	1.754	1.889	2.795	1.212	0.964	1.152
14	인산염인	0.023	0.024	0.031	0.014	0.012	0.007	0.003
15	총인	0.035	0.027	0.032	0.014	0.021	0.007	0.004
16	엽록소	2.1	2.8	2.8	1.5	2.4	1.4	1.5
17	부유물질	5.5	4.1	5	2.4	7.9	4.2	2.7
18	총대장균군	8600	20500	7100	9700	8600	6100	3600
19	분원성대장균군	900	4600	1300	1000	1500	700	500

범주형 계량형 원데이터(tui-chart.csv)

- 수질 지표
  - 수온: 물의 온도
  - 수소이온농도(pH): 물의 산성·알칼리성 정도
  - 용존산소(DO): 물에 녹아 있는 산소량
  - 총질소(T-N): 물속에 포함된 질소의 총량
  - 부유물질(SS): 물속에 떠 있는 고형물의 양
  - 생화학적 산소요구량(BOD): 물속의 유기물을 미생물이 분해할 때 소비하는 산소의 양

전처리 및 데이터 검사

- 전처리
  - 방향 바꾸고 컬럼이름 바꿔서 저장

	채수 지점	채수일	검사완 료일	수 온	수소이 온농도	용존산 소	전기전 도도	생화학적 산 소요구량
0	통학 교	2015-08-18	2015-08-31	23.1	7.8	9.9	165	0.6
1	동정 교	2015-08-18	2015-08-31	22.5	7.9	10.3	192	0.7
2	천천1 교	2015-08-18	2015-08-31	23	7.9	9.5	181	0.6
3	오봉 교	2015-08-18	2015-08-31	23	8	9.6	350	0.6
4	섬티 교	2015-08-18	2015-08-31	23.9	8.1	9.4	158	0.9

범주형 날짜형 계량형 tui-chart_transpose.csv

  - 널값 검사
  - 삭제, 대체 (평균, 중앙값, interpolate, imputer 등)

- 데이터 타입 검사
  - 어떻게 데이터를 분석하게 되는지 방향을 잡아 줌

```
채수지점              object
채수일               object
검사완료일             object
수온                float64
수소이온농도            float64
용존산소              float64
전기전도도              int64
생화학적 산소요구량       float64
화학적 산소요구량        float64
암모니아성 질소량        float64
이산화질소성 질소량       float64
질산염성 질소량         float64
총질소               float64
인산염인              float64
총인                float64
엽록소               float64
부유물질              float64
총대장균군               int64
분원성대장균군             int64
dtype: object
```

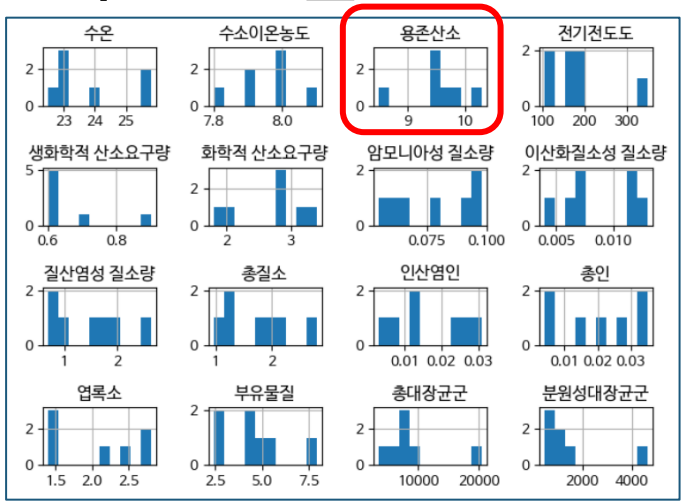
기본 통계 및 시각화 분석

▪ 기초통계

	수온	수소이온농도	용존산소	전기전도도	생화학적 산소요구량	화학적 산소요구량	암모니아성 질소량	이산화질소성 질소량	질산염성 질소량	총질소	인산염인	총인	엽록소	부유물질	총대장균군	분원성대장균군
count	7.000000	7.000000	7.000000	7.000000	7.000000	7.000000	7.000000	7.000000	7.000000	7.000000	7.00000	7.000000	7.000000	7.000000	7.000000	7.000000
mean	23.842857	7.957143	9.528571	180.142857	0.657143	2.700000	0.078143	0.008714	1.496714	1.703571	0.01700	0.020000	2.071429	4.542857	9171.428571	1500.000000
std	1.335237	0.097590	0.549892	81.925634	0.113389	0.559762	0.017668	0.003546	0.698308	0.649153	0.01077	0.012111	0.615668	1.857289	5385.695339	1408.308678
min	22.500000	7.800000	8.500000	106.000000	0.600000	1.800000	0.055000	0.004000	0.690000	0.964000	0.00300	0.004000	1.400000	2.400000	3600.000000	500.000000
25%	23.000000	7.900000	9.450000	133.500000	0.600000	2.450000	0.064000	0.006500	0.923000	1.182000	0.00950	0.010500	1.500000	3.400000	6600.000000	800.000000
50%	23.100000	8.000000	9.500000	165.000000	0.600000	2.800000	0.078000	0.007000	1.584000	1.754000	0.01400	0.021000	2.100000	4.200000	8600.000000	1000.000000
75%	24.750000	8.000000	9.750000	186.500000	0.650000	3.000000	0.094000	0.012000	1.863500	2.024000	0.02600	0.029500	2.600000	5.250000	9150.000000	1400.000000
max	25.800000	8.100000	10.300000	350.000000	0.900000	3.400000	0.098000	0.013000	2.630000	2.795000	0.03100	0.035000	2.800000	7.900000	20500.000000	4600.000000

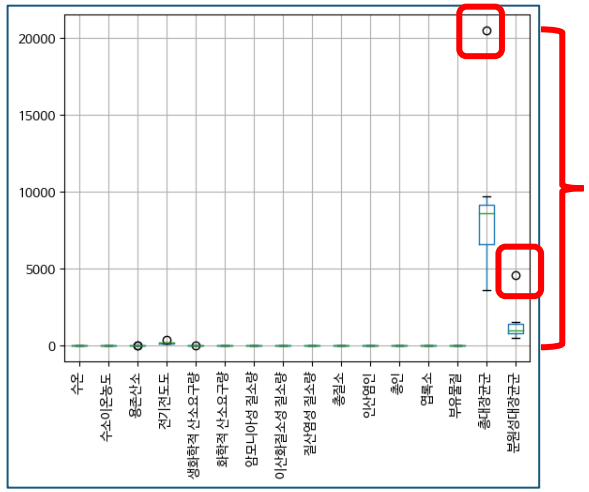
데이터 개수, 평균, 표준편차,제1사분위수, 중앙값, 제3사분위수, 최댓값 파악

▪ 히스토그램



변수별 데이터의 분포, 예측하려고 하는 변수와 비슷한 패턴의 분포가 있는지 등 파악

▪ 박스플랏

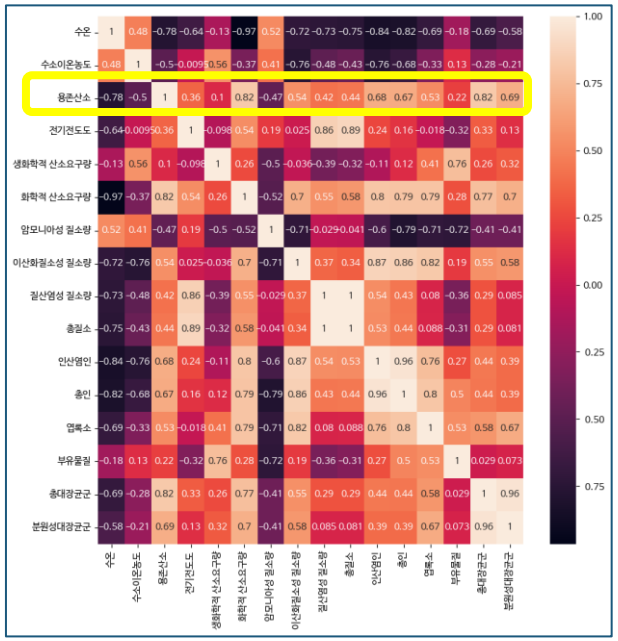


변수별 데이터의 범위를 파악하고, 이상치가 있는지 등 파악

데이터 시각화

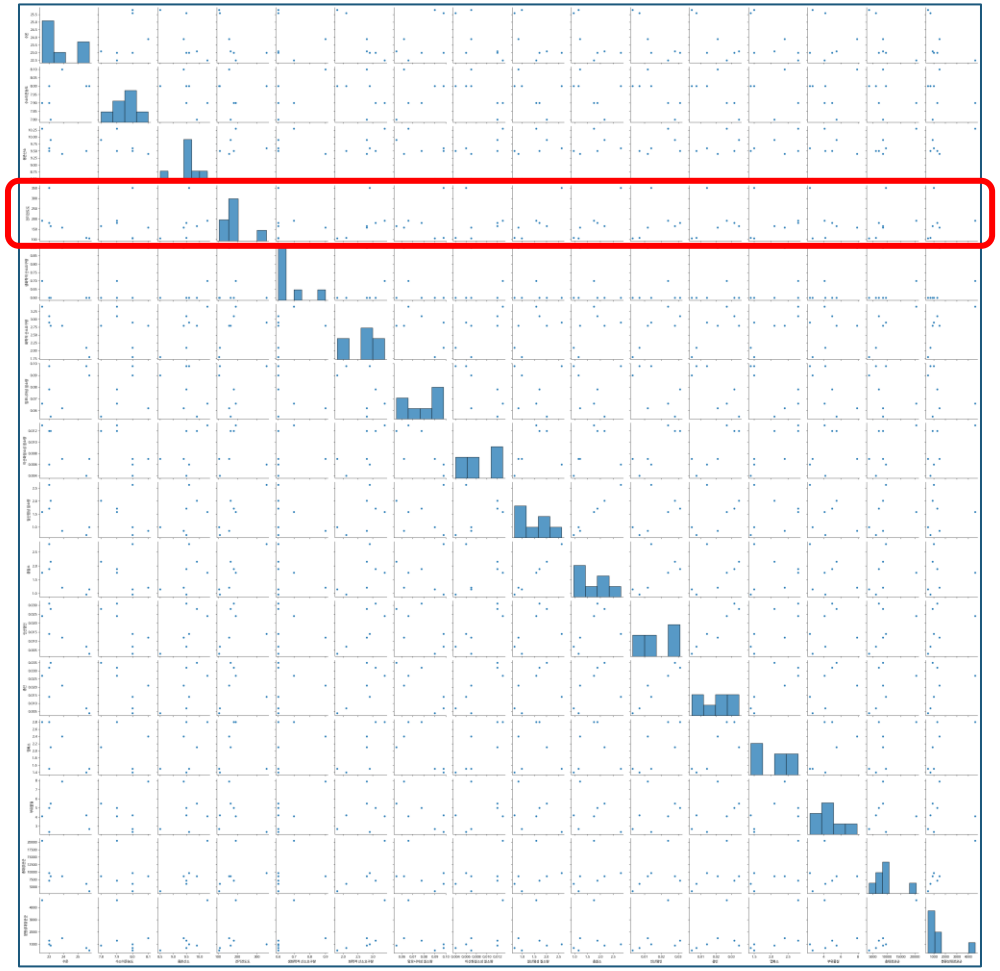
▪ 상관관계

	수온	수소이온농도	용존산소	전기전도도	생화학적 산소요구량	화학적 산소요구량	암모니아성 질소량	이산화질소성 질소량	질산염성 질소량	총질소	인산염인	총인	엽록소	부유물질	총대장균군	분원성대장균군
수온	1.000000	0.476900	-0.775993	-0.639824	-0.128954	-0.965551	0.523216	-0.718675	-0.729119	-0.747864	-0.835597	-0.821454	-0.691640	-0.182321	-0.691158	-0.575224
용존산소	-0.775993	-0.501356	1.000000	0.358013	0.103102	0.817608	-0.467111	0.543427	0.416047	0.435331	0.681017	0.673222	0.529568	0.215643	0.816899	0.686538
전기전도도	-0.639824	-0.009530	0.358013	1.000000	-0.097909	0.538973	0.189400	0.024836	0.859010	0.888900	0.241585	0.157231	-0.017749	-0.324925	0.330604	0.132609
생화학적 산소요구량	-0.128954	0.559431	0.103102	-0.097909	1.000000	0.262587	-0.503927	-0.035533	-0.388112	-0.322498	-0.109179	0.121370	0.409273	0.762007	0.262393	0.323549
화학적 산소요구량	-0.965551	-0.366118	0.817608	0.538973	0.262587	1.000000	-0.524118	0.696998	0.553741	0.579894	0.804469	0.794113	0.793126	0.278943	0.771219	0.699803
암모니아성 질소량	0.523216	0.410133	-0.467111	0.189400	-0.503927	-0.524118	1.000000	-0.714941	-0.029473	-0.040640	-0.599976	-0.792186	-0.710519	-0.722475	-0.405266	-0.411285
이산화질소성 질소량	-0.718675	-0.763794	0.543427	0.024836	-0.035533	0.696998	-0.714941	1.000000	0.368778	0.335567	0.872886	0.861675	0.820218	0.191988	0.553729	0.584113
질산염성 질소량	-0.729119	-0.484940	0.416047	0.859010	-0.388112	0.553741	-0.029473	0.368778	1.000000	0.995698	0.537694	0.434988	0.079720	-0.363518	0.287953	0.084568
총질소	-0.747864	-0.431009	0.435331	0.888900	-0.322498	0.579894	-0.040640	0.335567	0.995698	1.000000	0.530637	0.441151	0.088164	-0.306977	0.292194	0.080853
인산염인	-0.835597	-0.761124	0.681017	0.241585	-0.109179	0.804469	-0.599976	0.872886	0.537694	0.530637	1.000000	0.957053	0.764093	0.272451	0.442485	0.393373
총인	-0.821454	-0.676891	0.673222	0.157231	0.121370	0.794113	-0.792186	0.861675	0.434988	0.441151	0.957053	1.000000	0.802473	0.495712	0.437467	0.387950
엽록소	-0.691640	-0.328910	0.529568	-0.017749	0.409273	0.793126	-0.710519	0.820218	0.079720	0.088164	0.764093	0.802473	1.000000	0.531796	0.577250	0.670856
부유물질	-0.182321	0.131361	0.215643	-0.324925	0.762007	0.278943	-0.722475	0.191988	-0.363518	-0.306977	0.272451	0.495712	0.531796	1.000000	0.029301	0.073277
총대장균군	-0.691158	-0.275427	0.816899	0.330604	0.262393	0.771219	-0.405266	0.553729	0.287953	0.292194	0.442485	0.437467	0.577250	0.029301	1.000000	0.958945
분원성대장균군	-0.575224	-0.206155	0.686538	0.132609	0.323549	0.699803	-0.411285	0.584113	0.084568	0.080853	0.393373	0.387950	0.670856	0.073277	0.958945	1.000000



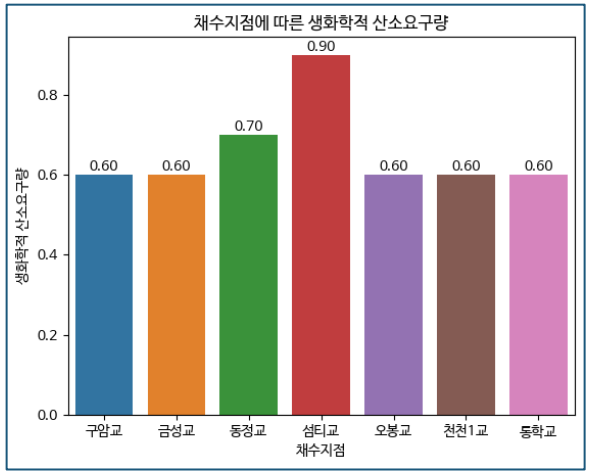
상관관계를 히트맵으로 시각화

▪ 산점도



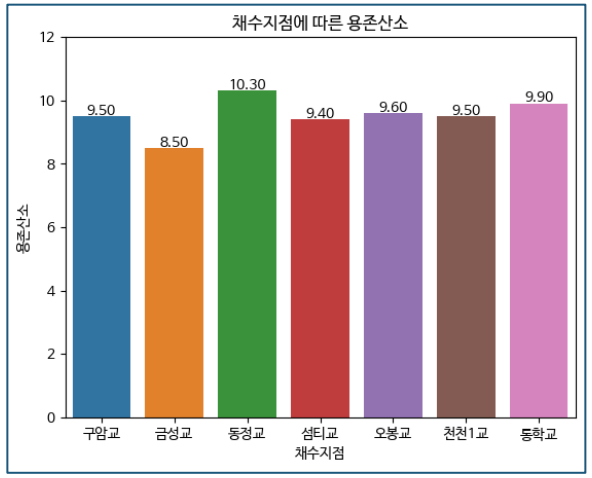
데이터 시각화

- 채수지점에 따른 생화학적 산소요구량



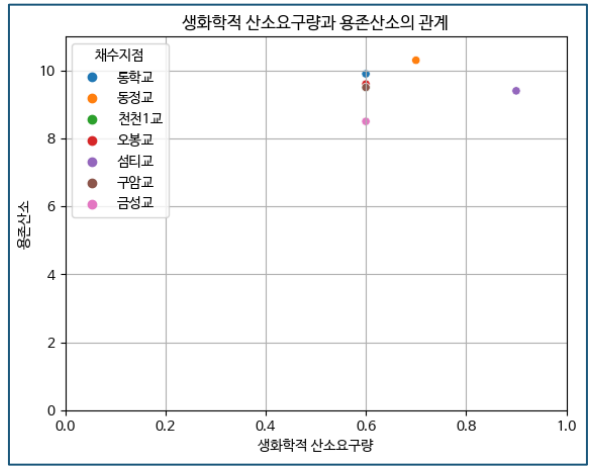

```
채수지점
구암교      0.6
금성교      0.6
동정교      0.7
섬티교      0.9
오봉교      0.6
천천1교     0.6
통학교      0.6
Name: 생화학적 산소요구량, dtype: float64
```

- 채수지점에 따른 용존 산소




```
채수지점
구암교      9.5
금성교      8.5
동정교     10.3
섬티교      9.4
오봉교      9.6
천천1교     9.5
통학교      9.9
Name: 용존산소, dtype: float64
```

- 생화학적 산소요구량과 용존 산소의 관계



Jupyterlab으로 데이터 탐색

데이터 이해를 위한 파이썬 코드 예시

```
import pandas as pd

df =
pd.read_csv('/content/bigmart_train.cs
v’)
df.head()


# 데이터 구조
print("데이터 크기:", df.shape)
print("\n변수 정보:")
print(df.info())
```

```
# 결측치
print("\n결측치:")
print(df.isnull().sum())


# 기초 통계
print("\n기초 통계:")
print(df.describe())


import matplotlib.pyplot as plt
import seaborn as sns

# 변수별 분포
df.hist(figsize=(15, 10), bins=20)
plt.tight_layout()
plt.show()
```

기초통계 분석을 위한 파이썬 코드

- **데이터 크기:** `df.shape`
- **변수명:** `df.columns`
- **데이터 타입:** `df.dtypes`
- **데이터 정보:** `df.info()`
- **평균:** `df.mean()`
- **표준편차:** `df.std()`
- **요약 통계량:** `df.describe()`

데이터 시각화를 위한 파이썬 코드 예시

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

df = pd.read_csv("data.csv")

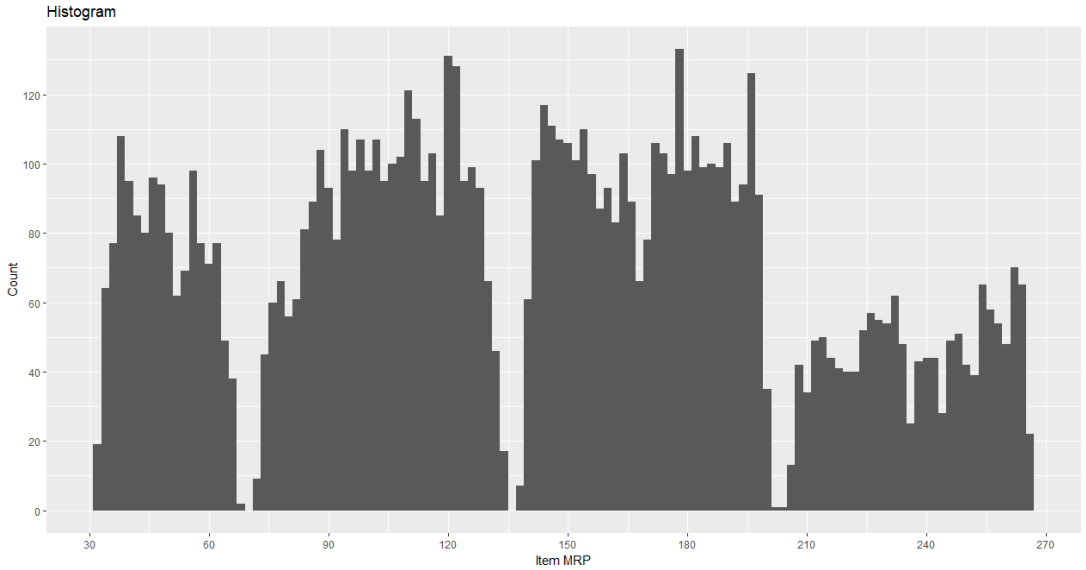
plt.figure(figsize=(8, 4))
plt.subplot(131)
plt.hist(df.age) # 히스토그램
```

```
plt.subplot(132)
plt.boxplot(df.salary) # 박스플랏


plt.subplot(133)
plt.scatter(df.age, df.salary) # 산점도
plt.tight_layout()
plt.show()


sns.pairplot(df) # 페어플랏
plt.show()
```

Histogram 히스토그램



- Used to plot continuous variable. 한개의 연속변수의 분포를 보여줌
- It breaks the data into bins and shows frequency distribution of these bins. 데이터를 빈으로 나눠서 빈도테이블을 만들고 그것을 그래프로!

```
plt.figure(figsize=(15, 6))
sns.histplot(data=df, x='Item_MRP', binwidth=3)
plt.title('Histogram')
plt.show()
```

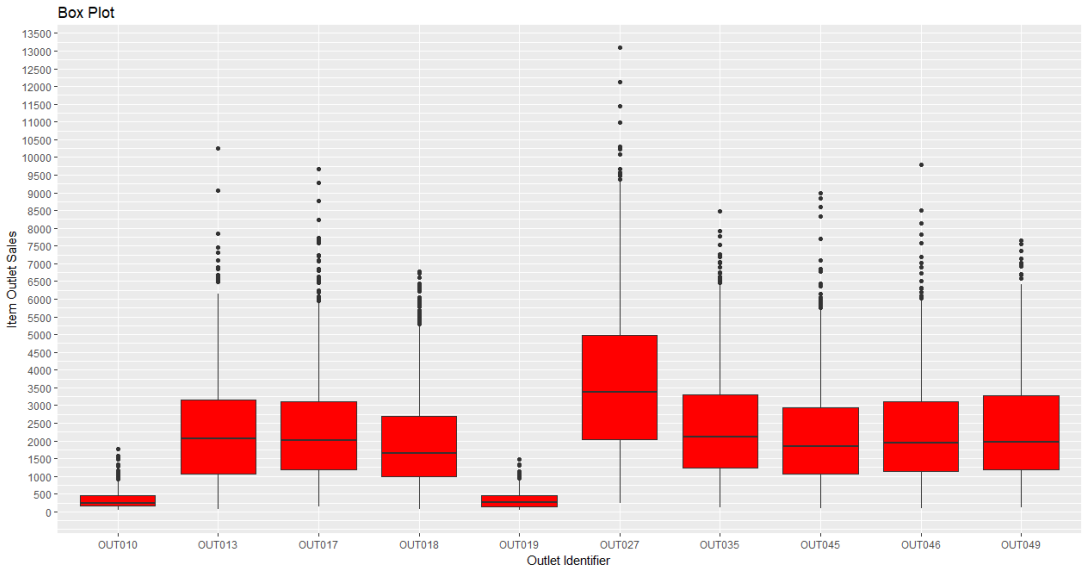
Scatter Plot 산점도



- Used to see the relationship between two continuous variables. 연속변수 사이의 관계

```
plt.figure(figsize=(15, 6))
sns.scatterplot(data=df, x='Item_Visibility', y='Item_MRP', hue='Item_Type')
plt.legend(
    bbox_to_anchor=(1.1, 1),
    loc='upper center'
)
plt.title('Scatterplot')
plt.show()
```

Box Plot 박스플랏

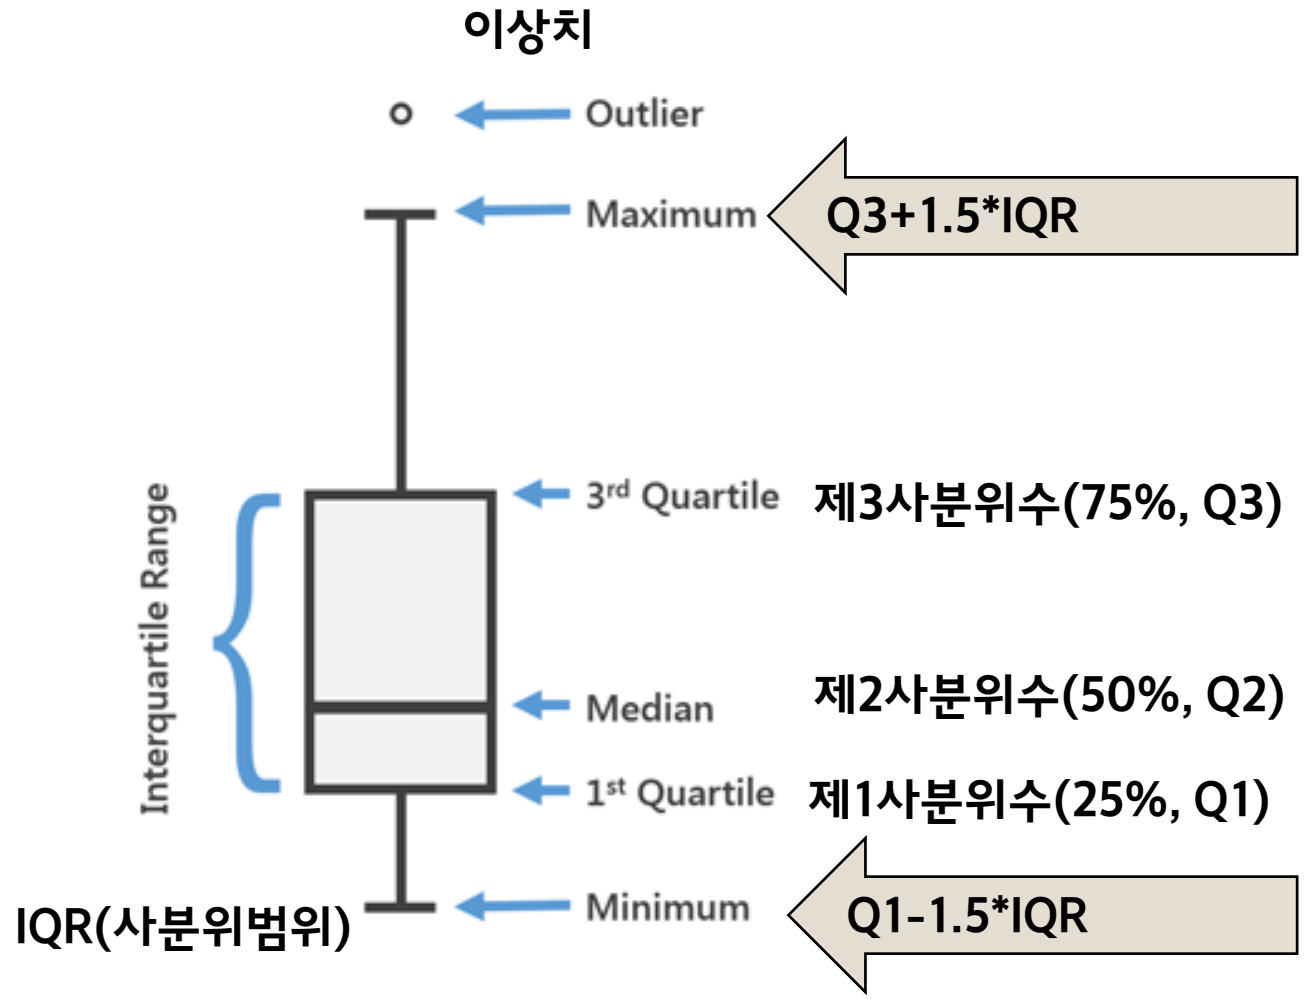


- Used to plot a combination of categorical and continuous variables. 범주와 연속형 변수를 그릴 때 사용
- Visualizes the spread of the data and detect outliers. 데이터의 퍼진 정도와 이상치를 볼 수 있음

```
plt.figure(figsize=(15, 6))
sns.boxplot(data=df, x='Outlet_Identifier', y='Item_Outlet_Sales',
color='red')
plt.title('Boxplot')
plt.show()
```

Box Plot 박스플랏

- The median of a data set is the value in the middle when the data items are arranged in ascending order.
  중위수(중앙값)는 데이터를 순서대로 정렬시 가운데 있는 값



EDA의 종류

Univariate 단변량

- Analyzes one variable. 한 변수 분석
- Use histograms and boxplots. 히스토그램과 박스플롯을 사용

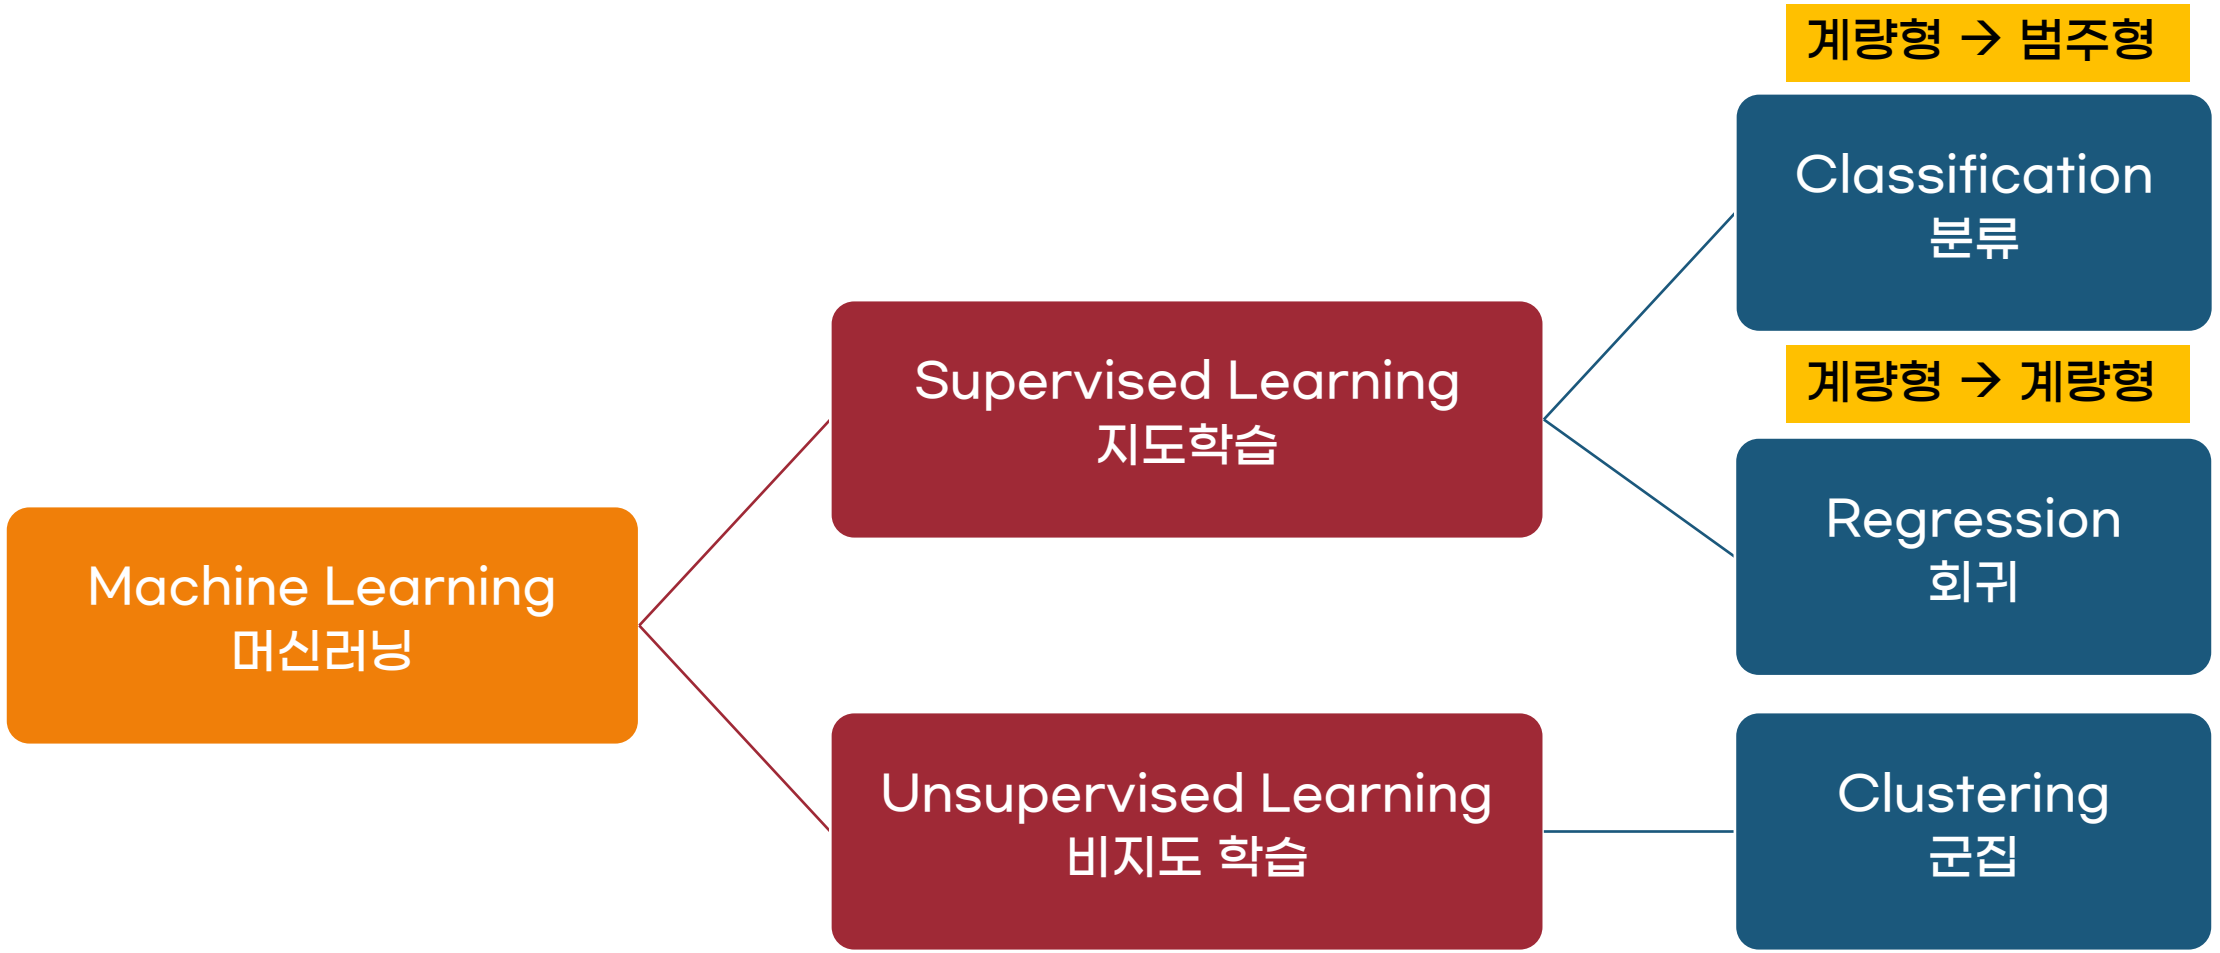
Bivariate 이변량

- Studies relationships between two variables. 두 변수 간의 관계
- Use scatter plot. 산점도 사용

Multivariate 다변량

- Looks at interactions between multiple variables. 여러 변수 간의 상호작용
- Use pair plots. 페어플롯 사용

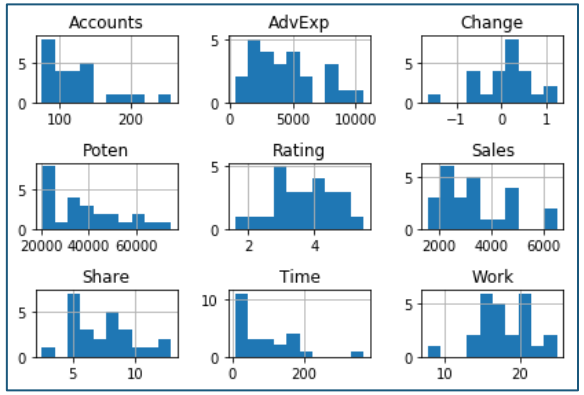
데이터 타입에 따른 머신러닝/인공지능 모델

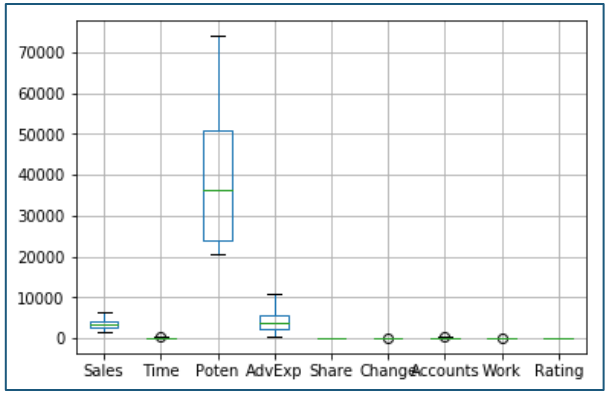


회귀모델을 위한 EDA

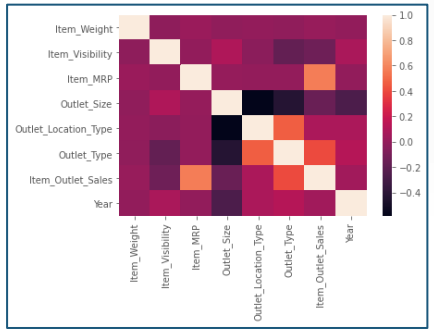
계량형 → 계량형

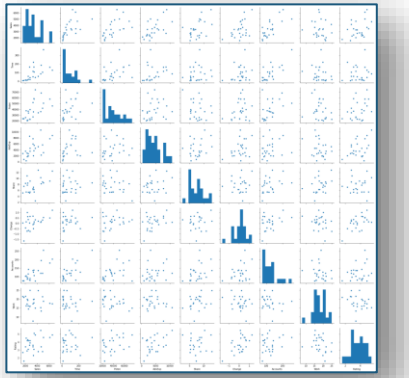
- Univariate analysis 일변량 분석
  - Descriptive statistics 기술통계
  - Frequency table 빈도테이블
  - Histogram, box plot 히스토그램, 박스플랏
- Multivariate analysis 다변량 분석
  - Correlation matrix, heatmap 상관관계 분석, 히트맵
  - Scatter plot 산점도











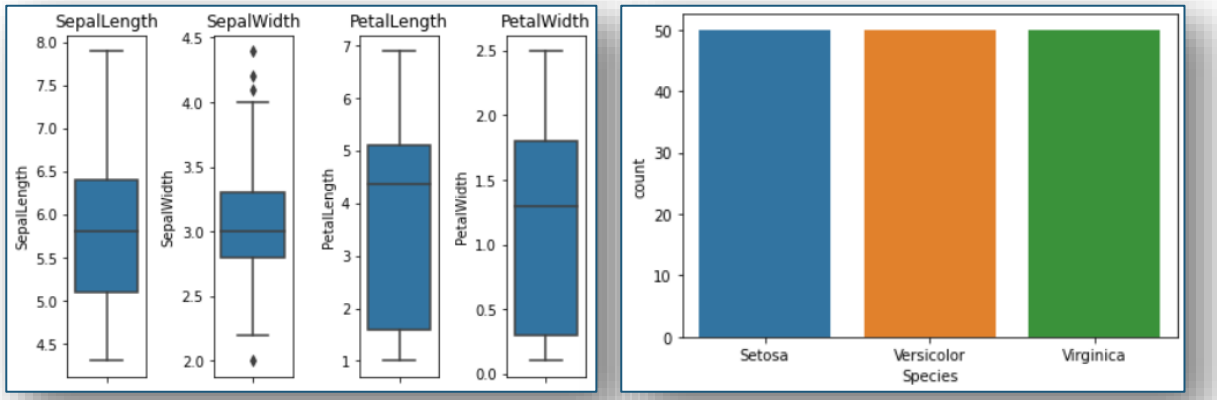
Jupyterlab으로 시각화한 모습

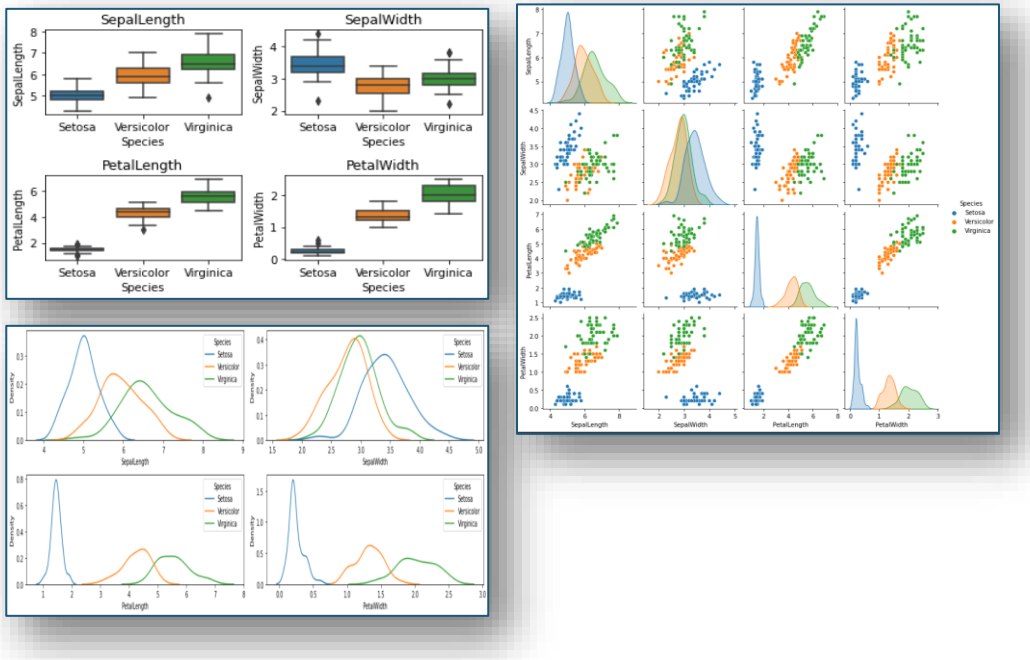
분류모델을 위한 시각화

계량형 → 범주형

- Univariate analysis 일변량 분석
  - Descriptive statistics 기술통계
  - Frequency table 빈도테이블,
  - Histogram, box plot, bar plot 히스토그램, 박스플랏, 막대그래프

- Multivariate analysis 다변량 분석
  - Box plot, density plot 박스플랏, 밀도그래프
  - Scatter plot 산점도





Jupyterlab으로 시각화한 모습

Sklearn Datasets 데이터셋

```
from sklearn import datasets
```

load_boston()	Load and return the boston house-prices dataset (regression).
load_iris()	Load and return the iris dataset (classification).
load_diabetes()	Load and return the diabetes dataset (regression).
load_digits([n_class])	Load and return the digits dataset (classification).
load_linnerud()	Load and return the linnerud dataset (multivariate regression).

5. Dataset loading utilities — scikit-learn 0.16.1 documentation (scikit-learn.org)

Iris Flowers Example 붓꽃 예제

The dataset contains 150 observations of iris flowers. There are four attributes of measurements of the flowers in centimeters: sepal length, sepal width, petal length, petal width. The fifth attribute is the species of the flower: Setosa, Versicolour, Virginica. Build a model to predict species of plants.
데이터 세트에는 붓꽃에 대한 150개의 관측치가 포함되어 있습니다. 꽃에 대한 4가지 속성을 포함하는데, 꽃받침 길이, 꽃받침 너비, 꽃잎 길이, 꽃잎 폭 (센티미터)이 있습니다. 다섯 번째 속성은 꽃의 종입니다. 식물의 종을 예측하는 모델을 만드시오.

Iris Dataset 붓꽃 데이터

```
from sklearn import datasets
iris = datasets.load_iris()
```

	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
1	5.1	3.5	1.4	0.2	setosa
2	4.9	3.0	1.4	0.2	setosa
3	4.7	3.2	1.3	0.2	setosa
4	4.6	3.1	1.5	0.2	setosa
5	5.0	3.6	1.4	0.2	setosa
6	5.4	3.9	1.7	0.4	setosa
7	4.6	3.4	1.4	0.3	setosa
8	5.0	3.4	1.5	0.2	setosa

붓꽃 데이터 기본 정보

```
print(iris.DESCR) #전체 설명
iris.data #데이터 2차배열
iris.feature_names #변수이름
iris.filename #파일이름과 위치
iris.target #y값
iris.target_names #y의 범주
```

```
.. _iris_dataset:

Iris plants dataset
--------------------

**Data Set Characteristics:**

:Number of Instances: 150 (50 in each of three classes)
:Number of Attributes: 4 numeric, predictive attributes and the class
:Attribute Information:
    - sepal length in cm
    - sepal width in cm
    - petal length in cm
    - petal width in cm
    - class:
            - Iris-Setosa
            - Iris-Versicolour
            - Iris-Virginica

:Summary Statistics:

============== ==== ==== ======= ===== ====================
                Min  Max   Mean    SD   Class Correlation
============== ==== ==== ======= ===== ====================
sepal length:   4.3  7.9   5.84   0.83    0.7826
sepal width:    2.0  4.4   3.05   0.43   -0.4194
petal length:   1.0  6.9   3.76   1.76    0.9490  (high!)
petal width:    0.1  2.5   1.20   0.76    0.9565  (high!)
============== ==== ==== ======= ===== ====================

:Missing Attribute Values: None
:Class Distribution: 33.3% for each of 3 classes.
:Creator: R.A. Fisher
:Donor: Michael Marshall (MARSHALL%PLU@io.arc.nasa.gov)
:Date: July, 1988

The famous Iris database, first used by Sir R.A. Fisher. The dataset is taken
from Fisher's paper. Note that it's the same as in R, but not as in the UCI
Machine Learning Repository, which has two wrong data points.

This is perhaps the best known database to be found in the
pattern recognition literature.  Fisher's paper is a classic in the field and
is referenced frequently to this day.  (See Duda & Hart, for example.)  The
data set contains 3 classes of 50 instances each, where each class refers to a
type of iris plant.  One class is linearly separable from the other 2; the
latter are NOT linearly separable from each other.
```

Lab #3

- Load the iris dataset and create a data frame named df (including target and feature names). 붓꽃 데이터를 열어 타겟과 속성이름을 포함한 df 만들기
- Replace numeric category to string category (0 → setosa, 1 → versicolor, 3 → virginica). 숫자로 된 범주를 글자로 바꾸기
- Summarize the data frame. 데이터 프레임 요약
  - shape, head(20), describe(), groupby('class').size(), dtypes
  - Frequency table, frequency chart
- Data visualization. 데이터 시각화
  - Univariate plot - boxplot, histogram. 박스플랏과 히스토그램을 이용한 일변량 분석
  - Multivariate plot - scatter plot, box and whisker plot, density plot. 산점도, 박스플랏, 밀도그래프를 이용한 다변량 분석

데이터 프레임 생성

	sepal_length	sepal_width	petal_length	petal_width	species
0	5.1	3.5	1.4	0.2	0
1	4.9	3.0	1.4	0.2	0
2	4.7	3.2	1.3	0.2	0
3	4.6	3.1	1.5	0.2	0
4	5.0	3.6	1.4	0.2	0

```
# 데이터셋 생성
df = pd.DataFrame(iris.data, columns=['sepal_length',
'sepal_width', 'petal_length','petal_width'])
df['species'] = iris.target
df.head()
```

데이터 전처리

- 숫자로 표현된 범주를 문자열 범주로 변환

```
# 범주를 문자형으로 변환
df['species'].replace(0,'setosa', inplace=True)
df['species'].replace(1,'versicolor', inplace=True)
df['species'].replace(2,'virginica', inplace=True)
df.head()
```

	sepal_length	sepal_width	petal_length	petal_width	species
0	5.1	3.5	1.4	0.2	setosa
1	4.9	3.0	1.4	0.2	setosa
2	4.7	3.2	1.3	0.2	setosa
3	4.6	3.1	1.5	0.2	setosa
4	5.0	3.6	1.4	0.2	setosa

Frequency Table 빈도 테이블

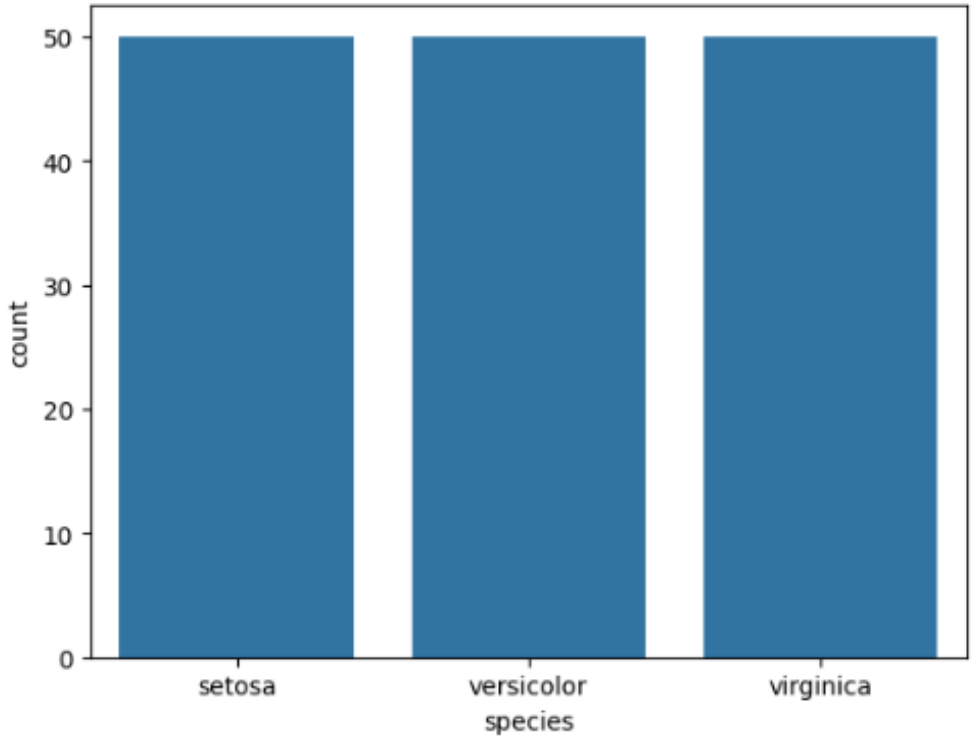
- Each class has the same number of instances (50 or 33% of the dataset). 각 클래스에 같은 수의 데이터를 가지고 있음. 각각 데이터셋의 33%

species	freq	percentage
setosa	50	33.333333
versicolor	50	33.333333
virginica	50	33.333333

```
# 빈도 테이블
tab = df.groupby('species').size()
pct = (tab / tab.sum())*100
tab = pd.concat([tab, pct], axis=1)
tab.columns = ['freq', 'percentage']
```

Frequency Chart 빈도 그래프

- The instances are evenly distributed across the three class. 모든 개체가 세개의 클래스에 골고루 분포되어 있음

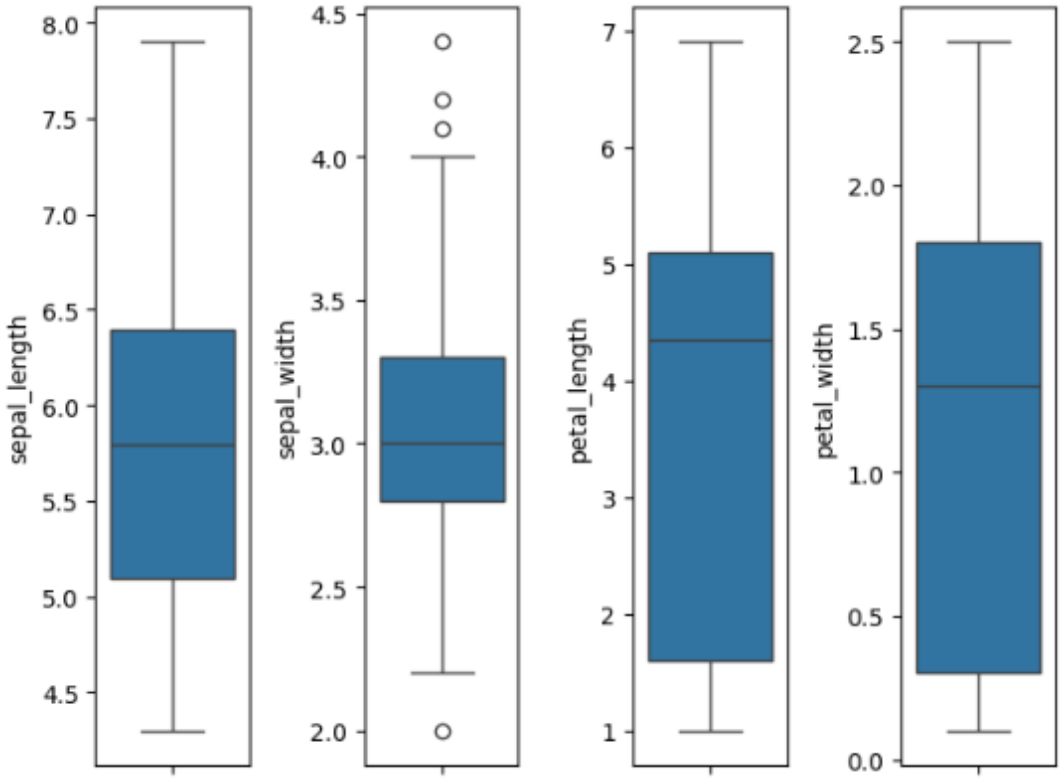



```
import seaborn as sns

sns.countplot(x=df['species'])
plt.show()
```

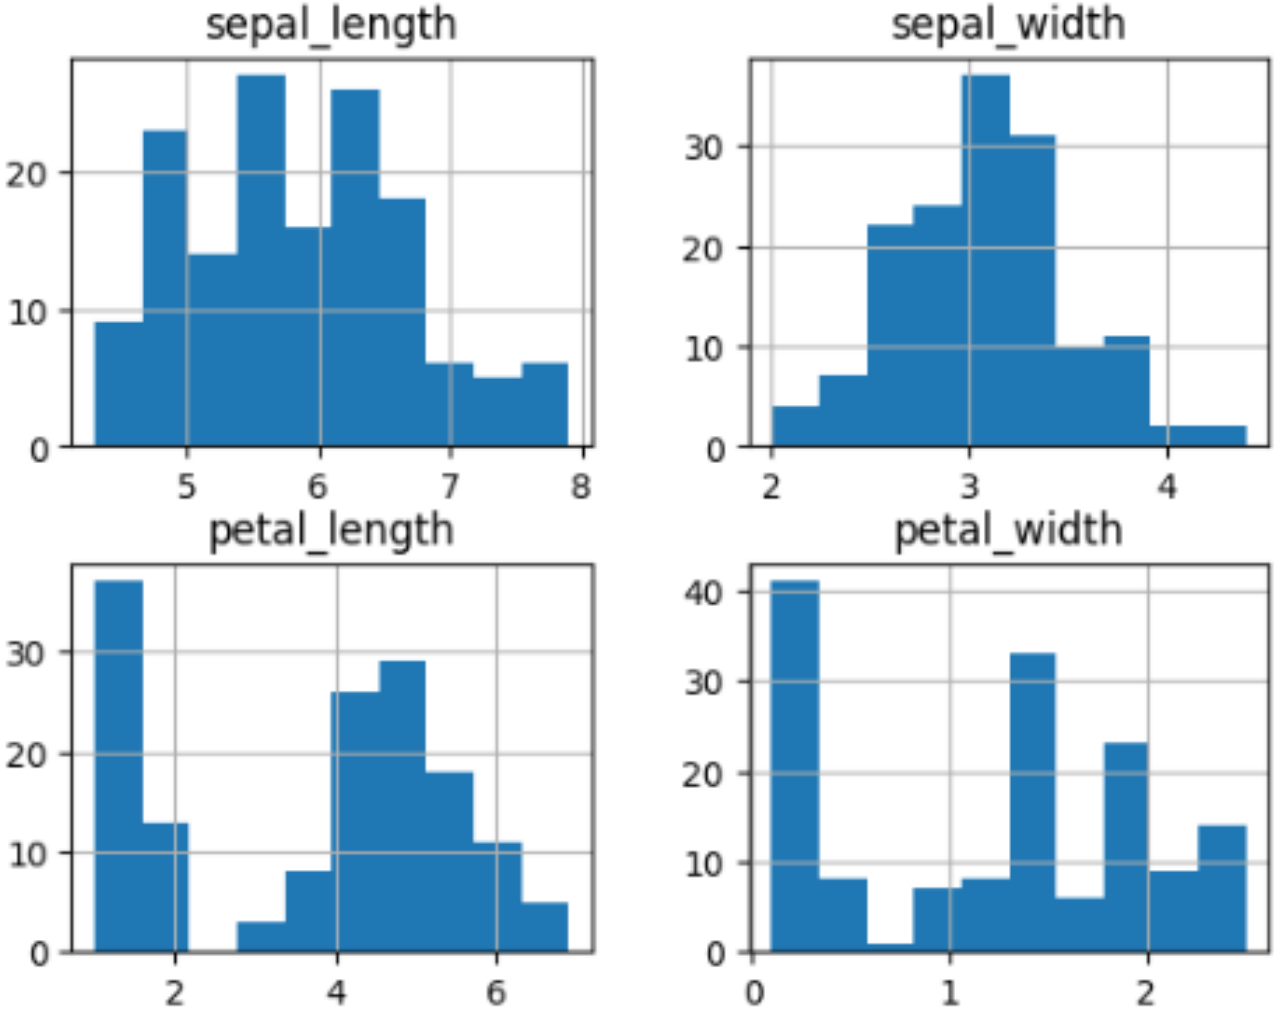
Univariate
박스플랏을 이용한 일변량 분석

- Plots of each individual variable. 개별 변수들을 그려서 분석




```
fig, axes = plt.subplots(ncols=4)
for i in range(4):
    sns.boxplot(data=df,
y=df.columns[i], ax=axes[i])
plt.tight_layout()
plt.show()
```

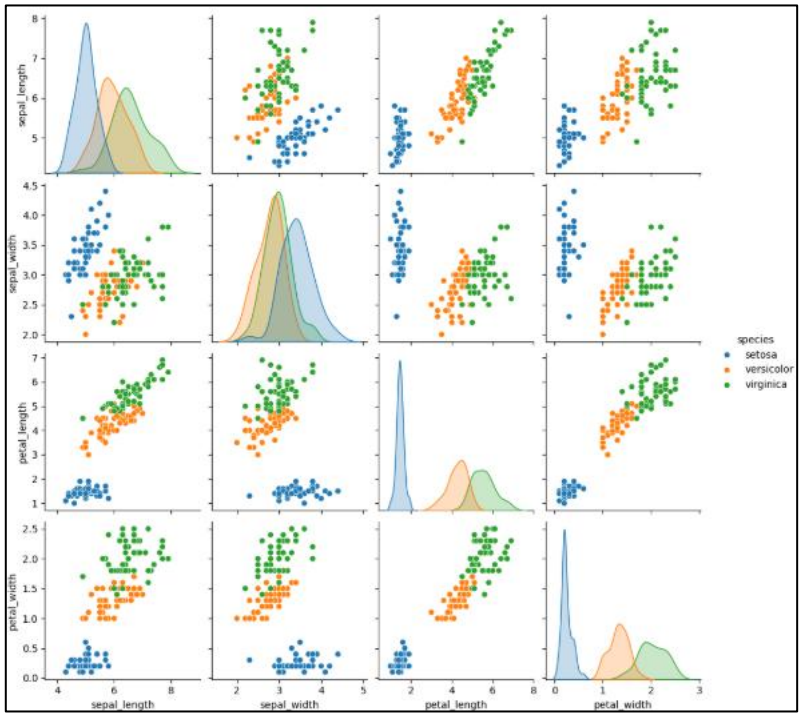
Univariate Plot
히스토그램을 이용한 일변량 분석




```
df.hist()
plt.show()
```

Multivariate Plot
산점도를 이용한 다변량 분석

- Scatter Matrix Plot
  산점도 매트릭스

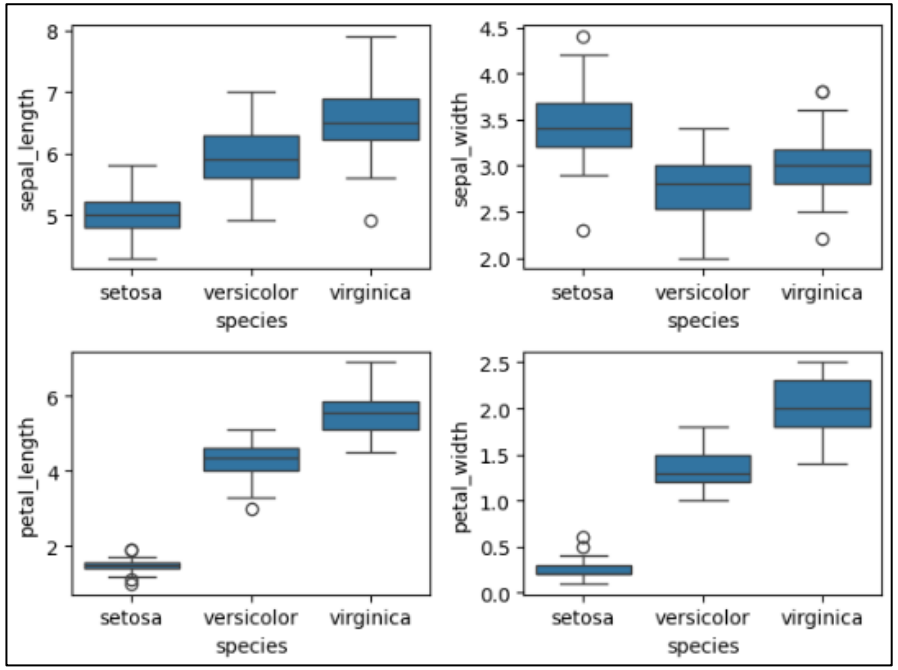


- All pairs of attributes and color the points by class. 모든 속성의 조합을 그래프로 그려서 클래스에 따라서 다른 컬러를 보여줌

```
sns.pairplot(df, hue='species')
plt.show()
```

Multivarite Plot
박스플랏을 이용한 다변량 분석

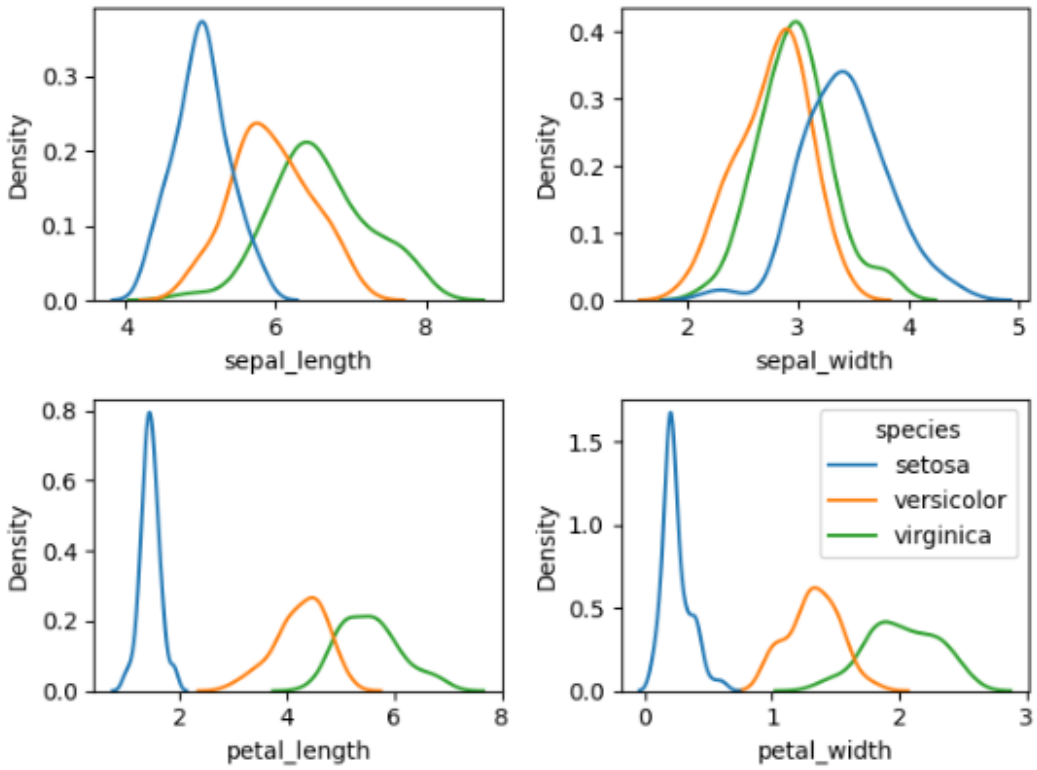
- Box and Whisker Plot 상자수염그래프




```
# 속성과 꽃 종류에 따른 박스플랏
fig, axes = plt.subplots(2,2)
sns.boxplot(x='species', y='sepal_length', data=df, ax=axes[0,0])
sns.boxplot(x='species', y='sepal_width', data=df, ax=axes[0,1])
sns.boxplot(x='species', y='petal_length', data=df, ax=axes[1,0])
sns.boxplot(x='species', y='petal_width', data=df, ax=axes[1,1])
plt.tight_layout()
plt.show()
```

Multivarite Plot
밀도그래프를 이용한 다변량 분석

- Density Plot 밀도그래프




```
# 속성과 꽃 종류에 따른 밀도그래프
fig, axes = plt.subplots(2,2)
sns.kdeplot(x='sepal_length', hue='species',
data=df, ax=axes[0,0], legend=None)
sns.kdeplot(x='sepal_width', hue='species',
data=df, ax=axes[0,1], legend=None)
sns.kdeplot(x='petal_length', hue='species',
data=df, ax=axes[1,0], legend=None)
sns.kdeplot(x='petal_width', hue='species',
data=df, ax=axes[1,1])
plt.tight_layout()
plt.show()
```